

Санкт-Петербургский государственный университет

Группа 22.М05-мм

*Королихин Владимир Игоревич*

Применение машинного обучения для  
улучшения модели трат автоматических  
стратегий назначения ставок в рекламных  
технологиях

Отчёт по учебной практике

Научный руководитель:  
к.ф.-м.н., доц. Е.Г.Михайлова

Консультант:  
руководитель группы разработки автостратегий ООО «Яндекс Технологии» С.К. Мить

Санкт-Петербург  
2023

# Оглавление

<b>Введение</b>	<b>3</b>
<b>1. Постановка задачи</b>	<b>5</b>
<b>2. Обзор</b>	<b>6</b>
2.1. Процесс запуска рекламной кампании . . . . .	6
2.2. Обзор видов автостратегий . . . . .	7
2.3. Описание текущего аналитического подхода расчета ставок	8
2.4. Недостатки аналитических формул . . . . .	10
<b>3. Сбор данных и обучение</b>	<b>12</b>
3.1. Сбор данных . . . . .	12
3.2. Выбор функции потерь . . . . .	13
3.3. Обучение модели . . . . .	14
3.4. Метрики качества и первые замеры . . . . .	15
<b>4. Результаты</b>	<b>16</b>
<b>Список литературы</b>	<b>17</b>

# Введение

В прошлом создание контекстной рекламы требовало от рекламодателя сложной ручной настройки. Для максимизации своих бизнес-показателей он должен был тщательно выбирать поисковые запросы, релевантные объявлению, а затем самостоятельно выставить ставки для участия в аукционе (алгоритм, решающий какую рекламу показать). Однако в последние годы произошел сдвиг в сторону автоматизации и упрощения работы с рекламой с использованием методов машинного обучения. Это привело к разработке автотаргетинга, который автоматически подбирает поисковые запросы для таргетирования рекламы, и автоматических стратегий, позволяющих рекламодателям доверить процесс эффективного расходования своих рекламных бюджетов рекламной площадке. В данной работе рассматриваются способы улучшения автоматических стратегий в Яндекс Директе. Это сервис для размещения объявлений контекстной рекламы на Яндексе и на сайтах-партнерах его рекламной сети.

Рекламодатель может выбирать различные виды автостратегий и их параметры исходя из целей бизнеса и знания стоимости собственных продуктов или определенных событий. С технической точки зрения он накладывает ограничения на некоторую функцию, которую необходимо оптимизировать. Ее результатом является набор управляющих воздействий, использующихся непосредственно в аукционе. Кроме выдерживания ограничений, такая функция должна быть адаптивна к внезапным изменениям в ее параметрах. Например, рекламодатель может изменить среднюю цену за клик. При такой постановке задачи точные аналитические формулы начинают работать не очень хорошо. В частности, не учитывается ситуация холодного старта - когда кампания только запустилась и данных, чтобы предугадать ее поведение в аукционе недостаточно. Для решения такой проблемы лучше всего подходит машинное обучение, которое позволяет эффективно находить сложные и не поддающиеся формализации структурные закономерности входных данных. Таким образом, исследование способов перехода от ана-

литического подхода решения задачи к моделям машинного обучения является актуальной задачей.

Можно доказать, что оптимальной моделью трат, максимизирующей конверсии при ограничениях на недельный бюджет или среднюю цену конверсии является такая, в которой ставка остается постоянной на протяжении всей недели. Вследствие этого возникает задача минимизации дисперсии ставок. Кроме того, ставки рекламных кампаний подчиняются степенному закону, что означает с одной стороны большое количество маленьких кампаний и малое количество больших, а с другой разброс целевой переменной по абсолютной величине. Такие ограничения сужают набор функций потерь и приемочных метрик. Само значение ставки вычисляется на основе оцененных коэффициентов, которые посчитаны по накопленной статистике из прошлого или же характеристик рекламной кампании в случае отсутствия такой статистики. Таким коэффициентом может выступать, например, временной таргетинг.

В данной работе рассматриваются различные подходы по переходу от аналитических формул в алгоритмах выставления ставок к алгоритмам машинного обучения, которые бы могли оценивать отдельные коэффициенты этих формул. Они позволяют адаптировать рекламную кампанию к изменениям в аукционе, более точно проводить аналитику кампании и улучшить модель трат, приводя ее к оптимальному состоянию.

# 1. Постановка задачи

Целью данной работы является адаптация текущих аналитических формул вычисления коэффициентов, участвующих в формулах управляющих воздействий автобюджета, на модели машинного обучения. Для достижения цели были поставлены следующие задачи:

1. Сделать обзор модели трат биддера автобюджета.
2. Реализовать сбор пула для обучения моделей.
3. Подобрать приемочные метрики, функцию потерь и обучить модель.
4. Провести эксперименты, проанализировать результаты и внедрить полученную модель.

## 2. Обзор

В этом разделе рассматривается работа автостратегий, возможные способы прогнозирования ставок, а также принцип работы рекламы в Яндекс Директе.

### 2.1. Процесс запуска рекламной кампании

Чтобы запустить рекламу, рекламодатель должен сначала создать набор рекламных материалов, которые будут рассказывать потенциальным клиентам о преимуществах продуктов или услуг. Материалы включают в себя рекламные тексты, изображения или видео, а также набор ссылок, которые будут вести по рекламным банерам. Следующим шагом рекламодатель должен задать таргетинг - набор критериев, которые позволят определить аудиторию, на которую будет рассчитана реклама. Существует также автотаргетинг, который автоматически подбирает запросы пользователя под заданные рекламные банеры. По данному набору ограничений решается попадет ли реклама в рекламный хит. Хит это процесс загрузки страницы с рекламными банерами. В случае положительного решения реклама начинает участие в аукционе, который в этом хите проводится. В аукционе рекламные кампании конкурируют за показ на банере, а торгуются между собой при помощи ставок [2]. Алгоритм, который выбирает ставку в каждом хите называется биддинг. В данной работе рассматривается только этап биддинга. Будем считать, что рекламные материалы нам заданы, а на таргетинг повлиять никак не можем. Единственное чем мы можем управлять это ставками, меняя которые можем добиваться эффективности рекламы.

Исторически самым первым способом биддинга являлось ручное управление ставками, которое перекладывало на рекламодателя необходимость задавать ставку для каждой ключевой фразы. В зависимости от ключевой фразы, по которой произошел таргетинг выставлялась ставка с которой реклама заходит в аукцион.

В последние годы произошел переход в сторону автоматизации выставления ставок, которые называются автостратегиями. Рекламодатель

тель с помощью ограничений ставит оптимизационную задачу на алгоритм автостратегии, которые в свою очередь считают оптимальную ставку. Например рекламодатель может поставить задачу максимизировать конверсии при заданной средней цене конверсии и ограничения на недельный бюджет.

## **2.2. Обзор видов автостратегий**

### **2.2.1. Автостратегии, основанные на правилах**

Автостратегии, основанные на правилах похожи на стратегии с ручным управлением ставок, но используют дополнительный набор правил или эвристик, выставленных рекламодателем, которые определяют, как следует корректировать ставки.

Такие автостратегии часто используются в ситуациях, когда существуют конкретные ограничения или требования, которые должны быть выполнены. Например, рекламодатель может хотеть, чтобы его реклама показывалась только в определенное время суток или в определенные дни недели. Более сложные правила могут включать калибровку ставки на определенную величину, если показатель кликабельности по его объявлению падает ниже определенного порога.

Одним из преимуществ автостратегий, основанных на правилах, является то, что они часто относительно просты в реализации и могут быть настроены в соответствии с конкретными потребностями рекламодателя. Однако они могут не учитывать такие факторы как поведение пользователей, конкуренция и меняющиеся рыночные условия.

Автостратегии, основанные на правилах наиболее эффективны при использовании в сочетании с другими алгоритмами [3], в частности с машинным обучением.

### **2.2.2. Автостратегии, использующие машинное обучение**

Автостратегии также могут использовать машинное обучение. Такие алгоритмы учатся по историческим данным и корректируют ставки

в режиме реального времени на основе различных факторов, таких как размещение рекламы или таргетинг на аудиторию. Например в статье [1] изучен метод прогнозирования поведения ставок с использованием градиентного бустинга на решающих деревьях. Для последующих корректировок авторы используют линейную регрессию.

В работе [2] авторы использовали обучение с подкреплением для обучения модели автоматического назначения ставок, которая показала хорошие результаты на A/B тестировании.

К сожалению, переиспользовать какие-либо вышеперечисленные подходы не представляется возможным из-за сложившихся внутри компании процессов по обучению моделей, в частности используется Catboost. С другой стороны, в данной работе не ставится цель предсказывать ставки, а лишь коэффициенты в формулах. Конечно, в будущем планируется перейти на полностью машинно-ориентированный подход, но это более сложная задача.

## 2.3. Описание текущего аналитического подхода расчета ставок

Рассмотрим, какой будет являться оптимальная ставка при следующих условиях:

Теорема: Если выполнено хотя бы одно из следующих ограничений:

1. Задана средняя цена конверсии
2. Задано ограничение на период работы рекламной кампании

Тогда оптимальной будет такая ставка, которая остается постоянной на протяжении всей работы рекламной кампании

Доказательство:




Рис. 1: количество конверсий и цена конверсии



На рисунке изображены хиты, которые произойдут в течение недели. Ширина столбика это количество конверсий, а высота это цена конверсии. Таким образом график в терминах CPA, т.е. Cost per action - средняя цена конверсии.

Для начала покажем какой будет искомая ставка. Постепенно поднимая линию выше, мы будем покупать все более дорогие конверсии. Вследствие этого вырастет бюджет, который мы за неделю потратили и средняя цена конверсии. Таким образом, в какой-то момент мы достигнем одного из ограничений. Ставка, которая при этом получится и будет оптимальной.

Предположим существует другой алгоритм, который смог купить больше конверсий, чем наш. Значит он должен был купить какое-то количество конверсий над чертой, так как все что ниже купил наш алгоритм. Возможно он отказался от части конверсий, которые купил наш алгоритм, однако ему нужно их будет докупить из тех, что находятся над чертой и соответственно дороже. Следовательно вырастет либо потраченный недельный бюджет, либо средняя цена конверсии, что противоречит условию.

Примечание: в доказательстве алгоритма мы пользуемся предположением, что нам заранее известно ожидаемое количество конверсий в каждом хите.

В Яндекс Директе существует большое количество автостратегий. Можно максимизировать конверсии/установки/клики/показы с различными видами ограничений на среднюю цену события (например конверсий) и/или на недельный/периодный бюджет с оплатой за показы/клики/конверсии. Все перечисленные автостратегии объединяет общая схема подсчета ставок. Для определенности в работе рассматривается оптимизация конверсий с ограничением на недельный бюджет.

Рассмотрим текущий аналитический подход расчета ставки для данного случая:

- Пусть  $T(t)$  - средняя интенсивность трафика, не зависящая от заказа, а зависящая от количества пользователей в интернете в

данный момент времени. Например, ночью этот параметр будет меньше, чем днем.

При этом:  $\int_{week} T(t)dt = 1$

- Тогда интенсивность трат в текущий момент времени ( $EventCost$ ) можно связать со ставкой на заказ ( $Bid$ ), где  $C$  - некоторая константа, зависящая от заказа, а  $P \geq 1$  - степень к ставке, которая позволяет захватывать более дорогие места показа, чтобы быстрее прийти к стационарному состоянию:

$$EventCost(t) = C \cdot Bid(t)^P \cdot T(t) \quad (1)$$

- Проинтегрировав формулу (1), можно выразить ставку на заказ на оставшийся период работы кампании:

$$Bid = \left( \frac{WeekLimit - SpentCost(now)}{C(now) \cdot \int_{now}^{week} T(t)dt} \right)^{\frac{1}{P}}, \quad (2)$$

где  $WeekLimit$  - ограничение на недельный бюджет, а  $SpentCost$  - траты к текущему моменту времени

- Аналогично можно выразить и константу  $C$ :

$$C(now) = \frac{\int_{now-week}^{week} EventCost(t)dt}{\int_{now-week}^{week} Bid(t)^P \cdot T(t)dt} \quad (3)$$

## 2.4. Недостатки аналитических формул

Ранее было показано, что в идеальном случае ставка на заказ должна быть постоянной на протяжении всей работы кампании. К сожалению, в реальном мире такого добиться очень сложно из-за множества проблем. Например:

- События связанные, с резким увеличением потока клиентов. Например, черная пятница.
- Изменения рекламодателем настроек кампании.
- Различные внутренние поломки алгоритмов рекламы

Для вычисления ставки, исходя из формулы (2) нужно знать  $C(now)$ , которая оценивается по историческим данным согласно формуле (3). Из этого вытекает несколько недостатков текущего подхода:

1. В случае сезонных скачков (например, черной пятницы) изменится и объем трафика, приходящий по данному заказу, что повлияет на ставки. Вернуться после таких изменений к прежним значениям может быть проблематично
2. В случае старта кампании в формуле (3) возникает неопределенность  $\frac{0}{0}$ , решить которую помогают прайорные значения в числителе и знаменателе. По мере получения статистики прайоры уменьшаются, однако точность  $C$  на старте кампании остается под сомнением.

Решить данную проблему позволит машинное обучение, которое сможет эффективно использовать имеющиеся характеристики кампании для предсказания начальных ставок. А в будущем и накопленную статистику для адаптивной реакции на сезонные изменения.

## 3. Сбор данных и обучение

В данном разделе описывается процесс сбора обучающего датасета, подбор оптимальной функции потерь и метрик качества модели.

### 3.1. Сбор данных

Для успешного обучения модели машинного обучения необходимо правильно организовать процесс сбора данных. В данном случае, для сбора данных используются логи данных по всем рекламным кампаниям. Эти логи являются источником информации о событиях, которые происходят во время показа рекламы пользователю. Они содержат разнообразные параметры, такие как затраты рекламодателя за клик пользователя по его баннеру, время, прошедшее с момента последнего показа и другие данные. Имеющиеся логи за определенный промежуток агрегируются по часам. Для этого используются ключевые атрибуты - номер кампании (OrderID) и час (Hour). Такой подход позволяет объединить данные для каждой кампании в пределах отдельных часовых интервалов. Такая агрегация сокращает количество обрабатываемых строк в последующем пайплайне. Это позволяет ускорить и оптимизировать процесс обработки данных.

Следующий этап сбора данных представляет собой программу редьюсера, которая принимает логи данных по ключу OrderID и суммирует статистику в отсортированном по Hour порядке. В результате, накапливается кумулятивная сумма. В первом подходе было решено использовать два вида фичей: счетчиковые и оценочные. Счетчиковые фичи применяются к значениям, которые потенциально отражают активность рекламной кампании, такие как количество кликов или показов. Оценочные фичи, в свою очередь, используются для оценки целевой формулы с использованием аналитической формулы, которая была описана в прошлых разделах. Данные фичи можно посчитать с помощью кумулятивных сумм, взяв разность суммы за текущий момент времени и сумму, отстающую на заданное количество часов. В целях учета различных временных интервалов, процесс формирования фичей

осуществляется для разных окон, таких как 6 часов, 12 часов, 3 дня и 7 дней. Это позволяет модели машинного обучения анализировать работу рекламной кампании в разные периоды времени и тем самым лучше оценить активность и эффективность ее расходов.

Последним этапом является джойн фичей, которые не нуждаются в обработке редьюсером к данным, которые получаются на выходе из редьюсера. Это такие данные как заложенный недельный бюджет, количество оставшихся дней работы кампании и другие.

## 3.2. Выбор функции потерь

Мы решаем задачу регрессии, где таргет может принимать различные по масштабу значения. Рассмотрим некоторые функции потерь, которые можно взять для обучения модели машинного обучения:

### 1. Арифметические:

r2:

$$1 - \frac{\sum_{i=1}^n w_i \cdot (t_i - p_i)^2}{\sum_{i=1}^n w_i \cdot (t_i - \bar{t})^2}$$

mse:

$$\frac{\sum_{i=0}^N w_i * (t_i - p_i)^2}{\sum_{i=0}^N w_i}$$

rmse:

$$\sqrt{\frac{\sum_{i=0}^N w_i * (t_i - p_i)^2}{\sum_{i=0}^N w_i}}$$

Данные функции потерь могут плохо решать поставленную задачу, так как нам нужно штрафовать модель за ошибки одинаково "в X раз", а не за ошибки "на X", потому что у всех рекламных кампаний разный масштаб, однако они все одинаково важны. Продуктовая задача состоит в том, чтобы предсказывать интенсивность трат одинаково хорошо независимо от размера кампании, что данные функции не позволяют.

## 2. mare

$$\frac{1}{\sum_{i=1}^n w_i} \sum_{i=1}^n w_i \cdot \left| \frac{t_i - p_i}{t_i} \right| \times 100$$

Здесь возникает проблема деления на ноль. Рассмотрим пример, когда у нас есть кампания правильный прогноз которой 0.1, в датасете 9 раз встречается  $t=0$  и один раз  $t=1$ . Из-за этого делиться делиться будет на ноль из-за  $\max$  в знаменателе

## 3. log-loss

Область определения:  $t \in [0, 1] \cup p \in [0, 1]$

$$\text{Формула: } \frac{\sum_{i=0}^N -w_i(t_i \log(p_i) + (1-t_i) \log(1-p_i))}{\sum_{i=0}^N w_i}$$

Метрика подходит для задачи, когда таргет находится в пределах  $[0, 1]$ . В нашем случае это не так. Однако мы можем этого достичь, разделив его на максимальную величину, предварительно убрав потенциальные выбросы. Для этого предлагается убрать данные больше 95-го перцентиля.

## 4. rmsle

$$\sqrt{\frac{1}{\sum_{i=1}^n w_i} \sum_{i=1}^n w_i \cdot (\log(p_i + 1) - \log(t_i + 1))^2}$$

Такая метрика также подходит, ее преимущество в том, что таргет не нужно нормализовывать

Так как предполагается использовать CatBoost в качестве модели машинного обучения, возникает еще одна проблема: в процессе обучения строятся решающие деревья, в листах которого оказываются наиболее похожие семплы. В таком случае интуитивно хочется брать среднее из всех семплов в листе. В случае log-loss такое достигается, чего не скажешь про арифметические метрики и rmsle.

## 3.3. Обучение модели

Так как модель должна уметь пресказывать правильную интенсивность трат, то эти предсказания должны соответствовать деньгам, ко-

торые кампания потратила за промежуток времени, который оценивает модель. Таким образом, в качестве весов модели можно использовать множитель из формулы ожидаемых денег:  $EventCost(t) = C \cdot Bid(t)^P \cdot T(t)$ , то есть вес каждого семпла при обучении будет  $Bid(t)^P \cdot T(t)$ , где данные параметры считаются в редьюсере по заданным окнам.

### 3.4. Метрики качества и первые замеры

В прошлых разделах рассматривались недостатки функций ошибок: они чувствительны к масштабу. Поэтому в качестве метрики качества решено использовать метрику  $\text{llr}$ :

$$best\_const = \frac{\sum_{i=0}^N w_i t_i}{\sum_{i=0}^N w_i}$$

$$LL\_best\_const = \frac{\sum_{i=0}^N -w_i(t_i \log(best\_const) + (1-t_i) \log(1-best\_const))}{\sum_{i=0}^N w_i}$$

$$LLp = \frac{LL\_best\_const - LL}{best\_const}$$

Она имеет следующие преимущества:

1. возможность понять лучше ли модель константного прогноза
2. возможность сравнивать модели между собой
3. нет зависимости от масштаба

Сравнение по метрике  $\text{llr}$  делалось с аналитической моделью, где в качестве таргетов использовались исходная  $C$  и  $EventCost$ . Таким образом, проверяется что мы не только хорошо предсказываем интенсивность трат, но и умеем оценивать деньги, которые с помощью этой интенсивности будут получены.

В первой итерации удалось получить +5% по метрике  $\text{llr}$  для дата-сета  $C$  и +6

Таким образом, общий пайплайн сбора, обучения и замеров можно изобразить в виде схемы:




Рис. 2: общий пайплайн обучения

## 4. Результаты

В данной работе рассмотрена предметная область и поставлена задача. Также реализован инструмент сбора данных, обучена первая модель, проведены замеры качества. Составлен план для будущего решения:

1. Доработать текущий пайплайн, добавить больше признаков
2. Обучить модель на другие функции ошибок, сравнить с текущим подходом
3. Эксперименты и апробация результата



## Список литературы

- [1] Li Wei, Cui Ying Grace, Zhang Ruofei, and Mao Jianchang. Bid landscape forecasting in online advertising. — 2012. — Apr. 5. — US Patent App. 12/895,773.
- [2] Amin Kareem, Kearns Michael, Key Peter, and Schwaighofer Anton. Budget optimization for sponsored search: Censored learning in mdps // arXiv preprint arXiv:1210.4847. — 2012.
- [3] Berg Jordan, Greenwald Amy, Naroditskiy Victor, and Sodomka Eric. A first approach to autonomous bidding in ad auctions // Workshop on Trading Agent Design and Analysis at the 11th ACM Conference on Electronics Commerce. — 2010.